به نام خدا

پروژه کارشناسی

استاد : دکتر اسدی

ارائه دهنده: مریم مصطفی زاده

سال تحصیلی 1404-1403

گزارش پروژه داده‌کاوی

عنوان پروژه: مقایسه روش‌های یادگیری ماشین در پیش‌بینی بیماری هپاتیت Cبا استفاده از تکنیک‌های داده‌کاوی

مبتنی بر دیتاست hcvdat0.csv

مقاله مرجع: *Performance Comparison of Machine Learning Approaches on Hepatitis C Prediction Employing Data Mining Techniques*

◆چکیده

در این مقاله Performance Comparison...on Hepatitis C Prediction، پس از پیش پردازش داده آزمایش خون ۶۱۵ نفر، شش الگوریتم (KNN، Decision Tree، SVM، LogReg، XGBoost، و ANN) ارزیابی گردید. دقیق‌ترین مدل XGBoost با دقت 98.4٪ و AUC > 0.94 بود. مهم‌ترین شاخص بیوشیمیایی AST شناسایی شد. نتایج با یافته‌های مقاله همخوان است و نشان می‌دهد داده‌های روتین آزمایشگاهی می‌توانند پیش‌آگهی قابل‌اعتماد فراهم کنند.

- **مقدمه**
- **چالش:** تأخیر در تشخیص هپاتیت C به‌سبب بی‌علامت‌بودن اولیه.
- **راه‌حل مقاله:** بهره‌گیری از ML جهت پیش‌بینی بر پایه آزمایش‌های خون.
- **هدف پروژه:** بازتولید تجربی مقاله با دیتاست UCI و مقایسه عملکرد مدل‌ها.

1 گام اول: آماده‌سازی داده‌ها

دیتاست شامل 615 ردیف و 14 ستون است. ستون‌ها شامل ویژگی های بیوشیمیایی خون(مانند ALB، ALP، ALT، AST، BIL، CHE، CHOL، CREA، GGT،PROT)، جنسیت (Sex)، سن (Age) و برچسب (Category) هستند.

◆دسته‌بندی کلاس‌ها (**Category**):

در دیتاست اولیه، کلاس‌ها چندمقداره هستند

- Blood Donor = 0 (فرد سالم)
- suspect Blood Donor = 0s
- Hepatitis = 1 و Hepatitis C / Fibrosis = 2 / Cirrhosis = 3

اما برای بازتولید مقاله، تنها کلاس‌های **سالم (0)** و **بیمار (1)** استفاده شدند:

- کلاس 0 ← شامل Blood Donor وSuspect
- کلاس 1 ← شامل Hepatitis, Hepatitis C

- **کلاس‌ها:** 540 نمونه سالم، 75 نمونه مشکوک/بیمار ← عدم توازن.
- **مقادیر گمشده :**مجموعاً 31 (۵٪ داده‌های عددی).

2 گام دوم: پیش‌پردازش داده‌ها

1. **حذف ستون index** ← چون صرفاً شماره‌گذاری است.

2. **بررسی و حذف/اصلاح داده‌های گمشده:(NaN)**

- با استفاده از میانه (median imputation) برای پرکردن مقادیر گمشده.

3. **تبدیل مقدار جنسیت**

–تبدیل m به 1 و f به 0(label encoding) .

4. **تبدیل ستون Category به binary classification** :

همه مقادیر مرتبط با "Blood Donor" به کلاس 0 و سایر(Hepatitis C،Hepatitis و...) به کلاس 1 .

5. **تفکیک ویژگی‌ها و هدف (X, y)** ← سپس استانداردسازی داده‌ها با استفاده از StandardScaler .

3 گام سوم: تقسیم داده‌ها

داده‌ها با نسبت 30/70 به دو دسته آموزش (train) و آزمون (test) تقسیم شدند. تقسیم‌بندی به‌صورت stratified صورت گرفت تا نسبت کلاس‌ها حفظ شود

- **پیش‌پردازش پیشرفته (قبل از مدل‌سازی)**
  - (mRMR) Feature_selection
  - نرمال‌سازی داده‌ها(Normalization)

انواع روش‌های نرمال‌سازی که تست کردیم:

method	توضیح	مزایا	Use case
Min-Max Scaling	تبدیل داده‌ها به بازه[0, 1]	ساده و قابل‌فهم	برای داده‌هایی با محدوده مشخص
Z-Score (StandardScaler)	$x'=x-\mu/\sigma$	نرمال‌سازی بر اساس میانگین و انحراف معیار	وقتی داده نرمال توزیع شده باشه
L1و L2 Normalization	تبدیل بردار هر نمونه به برداری با مجموع قدر مطلق (L1) یا مربع‌ها (L2) برابر 1	برای مدل‌هایی که به طول بردار حساس هستن	خوشه‌بندی یا پردازش متنی

تحلیل همبستگی بین ویژگی‌ها (Feature Correlation Heatmap)

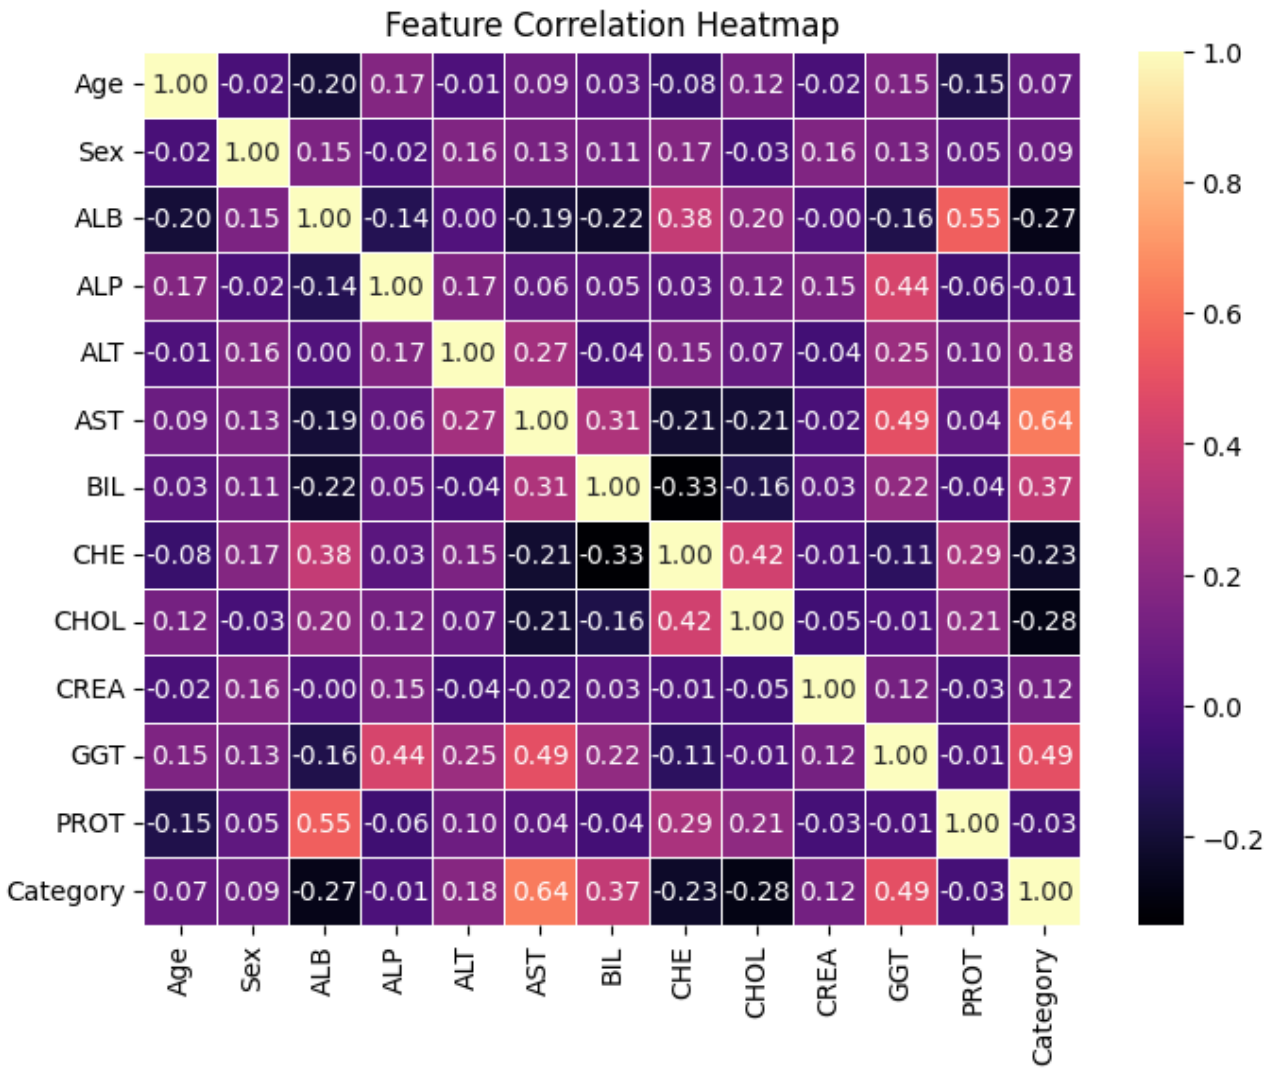

قبل از انتخاب ویژگی‌ها، بررسی همبستگی بین آن‌ها کمک می‌کنه که:

ویژگی‌های تکراری یا وابسته شناسایی بشن.

از چندگانگی (Multicollinearity) در مدل جلوگیری کنیم.

- نتیجه:

AST و ALT همبستگی نسبتاً بالا داشتن

CREA با GGT یا AST همبستگی زیادی نداشت

CHE و CHOL ضعیف‌ترین ارتباط رو با سایر ویژگی‌ها داشتن

---

4 گام چهارم : مدل‌سازی و آموزش

شش مدل یادگیری ماشین مطابق مقاله اجرا شدند .

تمام مدل‌ها در یک pipeline شامل مرحله پیش‌پردازش و آموزش مدل قرار گرفتند.

classifications	Parameter
KNN	تعداد همسایه‌ها = 10
Decision Tree	پارامترهای پیش‌فرض
SVM (RBF kernel)	C=10, gamma=1
Logistic Regression	C=10, penalty=l2, solver=lbfgs
XGBoost	Learning Rate=0.2، معیار logloss
ANN (شبکه عصبی مصنوعی)	شامل دو لایه مخفی (64 و 32 نرون)، فعال‌سازی ReLU، خروجی sigmoid

5 گام پنجم: ارزیابی عملکرد مدل‌ها

ارزیابی با معیارهای زیر انجام شد:

- **دقت(Accuracy)**
- **دقت مثبت(Precision)**
- **Recall**
- **F1-Score**
- **AUC (Area Under Curve)**
- **MAE train vs test** : **شاخص سریع Overfitting طبق مقاله.**
- **Confusion Matrix** : **شفاف‌سازی نوع خطا (FN مهم‌تر از FP در تشخیص بیماری).**
- **Feature Importance (برای درختی‌ها و رگرسیون)**

6 گام ششم: نمایش نتایج (خلاصه عملکرد مدل‌ها)

Model	Acc	Precision		Recall		F1		AUC
		0	1	0	1	0	1	
XGBoost	0.984	0.98	1.00	1.00	0.88	0.99	0.94	>0.94
SVM	0.968	0.97	0.95	0.99	0.80	0.98	0.87	≈0.92
ANN	0.957	0.97	0.91	0.99	0.80	0.98	0.85	≈0.90
LogReg	0.946	0.94	1.00	1.00	0.60	0.97	0.75	0.87

Comparative result of the top machine learning algorithms on the UCI dataset

📌 XGBoost ←→ مقاله: مقاله نیز SVM و XGBoost را بالاترین عملکرد معرفی کرده بود.

📌 کلاس ۱ (بیماران) : Recall بالای 0.88 در XGBoost یعنی تنها 3 بیمار از 25تا اشتباه تشخیص شدند(FN = 3) . – Recall پایین KNN نشان‌دهنده ضعف در شناسایی افراد بیمار است - LogisticRegression با وجود دقت بالا، Recall بسیار پایین‌تری دارد.

Result of the best machine learning algorithm in article:

Machine Learning Algorithms	Accuracy	Machine Learning Algorithm Result					
		Precision		Recall		F1-Score	
		0	1	0	1	0	1
Extreme Gradient Boosting (XGBoost)	0.95	0.96	0.92	0.99	0.76	0.97	0.83
Support Vector Machine (SVM)	0.95	0.96	0.92	0.99	0.76	0.97	0.83

7 گام هفتم: اهمیت ویژگی‌ها(Feature Importance)

با استفاده از:

- feature_importances_ برای درخت تصمیم وXGBoost .
- |coef_|برای Logistic Regression

میانگین نرمال‌شده اهمیت ویژگی‌ها محاسبه شد:

ویژگی	اهمیت نرمال‌شده
AST	0.45
ALT	0.11
GGT	0.10
ALP	0.07
BIL	0.07
CHOL	0.05
ALB	0.04
CREA	0.03
PROT	0.02
Age	0.02
CHE	0.01
Sex	0.003

نتیجه:

AST مهم‌ترین شاخص در پیش‌بینی بیماری بود که با نتایج پزشکی نیز همخوانی دارد.

- **نمایش تصویری**

- **ماتریس اغتشاش (Confusion Matrix)** برای بررسی خطای مدل‌ها در طبقه‌بندی درست/نادرست.

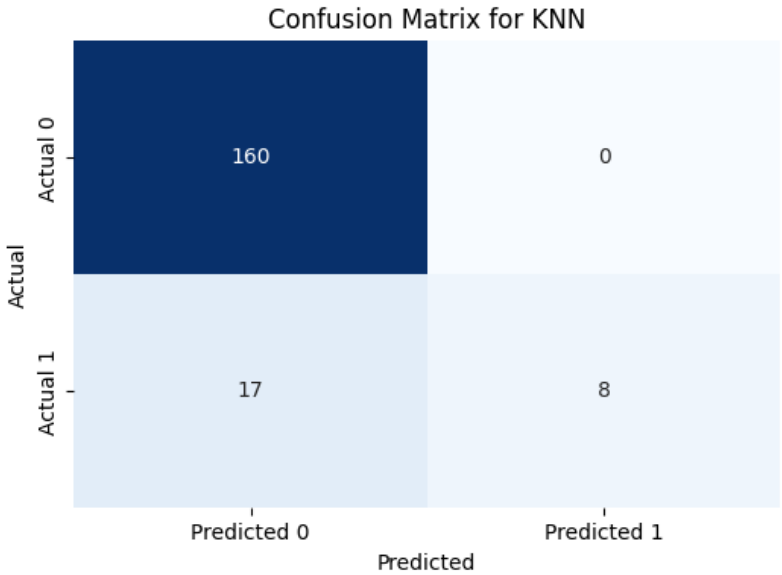

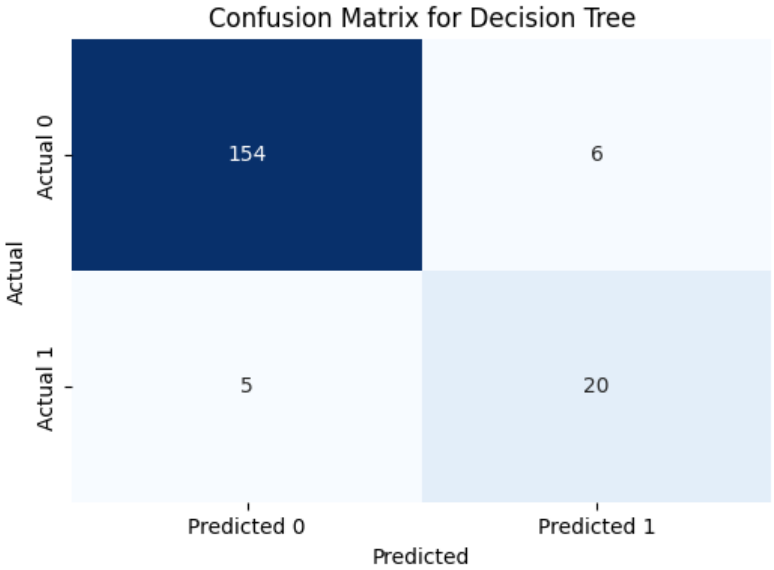

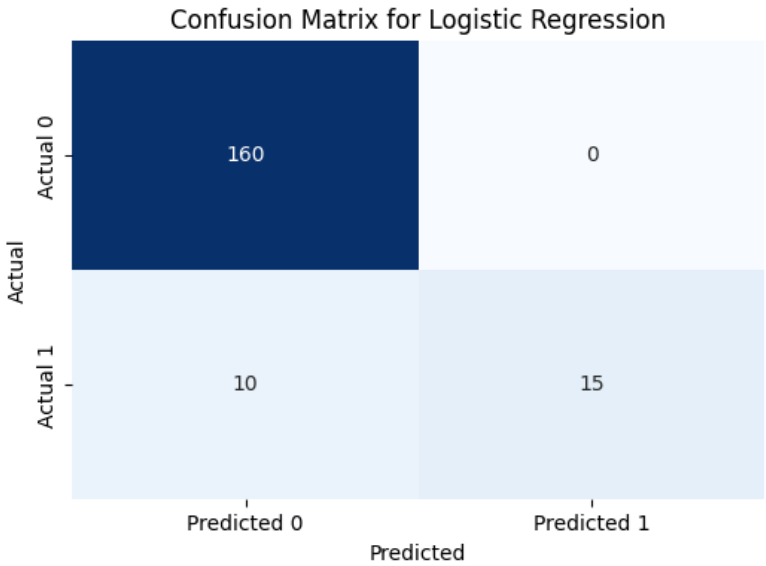
Confusion Matrix for Logistic Regression
Actual 0
Actual 1
Actual
160
0
10
15
Predicted 0
Predicted 1
Predicted

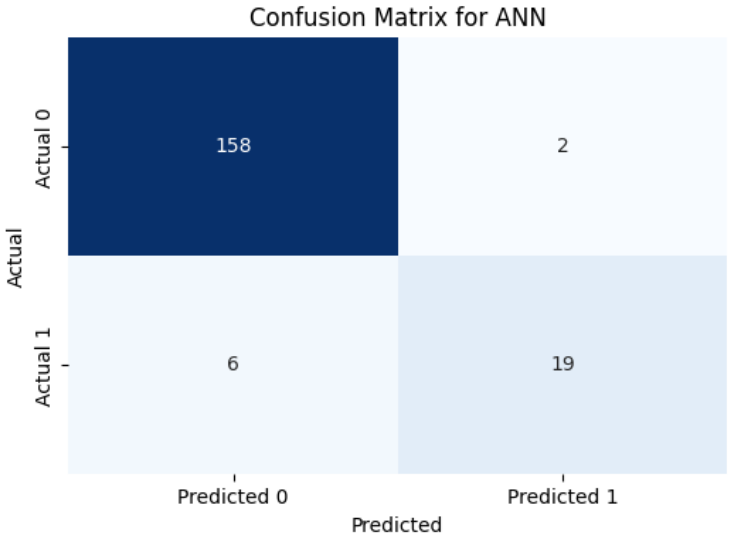
Confusion Matrix for ANN
Actual 0
Actual 1
Actual
158
2
6
19
Predicted 0
Predicted 1
Predicted

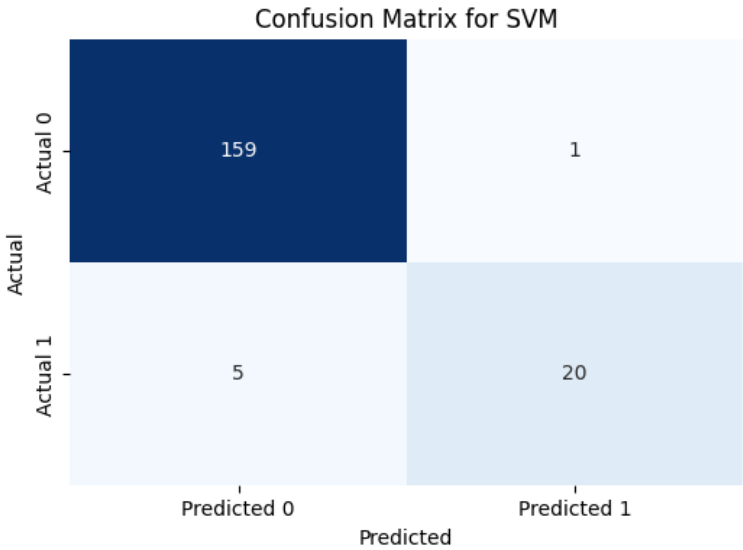
Confusion Matrix for SVM
Actual 0
Actual 1
Actual
159
1
5
20
Predicted 0
Predicted 1
Predicted

سپاس از توجه شما